ΟΙΚΟΝΟΜΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

ATHENS UNIVERSITY OF ECONOMICS AND BUSINESS

ΕΡΕΥΝΑ ΓΙΑ ΤΟΥΣ ΠΟΛΙΤΕΣ ΤΟΥ ILLINOIS

ΟΝΟΜΑΤΕΠΩΝΥΜΟ: **ΑΝΤΩΝΙΟ ΤΣΕΝΓΚΑ**

ΑΡ.ΜΗΤΡΩΟΥ: **6170103**

ΤΜΗΜΑ: **ΣΤΑΤΙΣΤΙΚΗΣ**

ΜΑΘΗΜΑ:**ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ**

ΕΞΑΜΗΝΟ: **ΕΑΡΙΝΟ 2023**

Περιεχόμενα

ΕΙΣΑΓΩΓΗ.....3
ΠΕΡΙΓΡΑΦΙΚΗ ΑΝΑΛΥΣΗ….....4
ΣΧΕΣΕΙΣ ΜΕΤΑΒΛΗΤΩΝ ΑΝΑ ΔΥΟ….....6
ΠΡΟΒΛΕΠΤΙΚΑ ΚΑΙ ΕΡΜΗΝΕΥΤΙΚΑ ΜΟΝΤΕΛΑ.....10
ΣΥΜΠΕΡΑΣΜΑΤΑ.....13
ΠΑΡΑΡΤΗΜΑ1ο.....14
ΠΑΡΑΡΤΗΜΑ2ο.....19
ΠΑΡΑΡΤΗΜΑ3ο.....24

ΕΙΣΑΓΩΓΗ

Η έρευνα του εργατικού δυναμικού γίνεται για την παραχώρηση πληροφοριών σχετικά με την αγορά εργασίας και το ποσοστό ανεργίας. Παρόλο που σε αρκετά άτομα είναι δυσνόητες οι εκτιμήσεις αυτές, προσπαθούμε να απλοποιήσουμε την διαδικασία όσο γίνετε συμπεριλαμβάνοντας τις απαραίτητες πληροφορίες για περιγραφή των ορισμών και τον μεθόδων που ακολουθούνται για τις εκτιμήσεις εργατικού δυναμικού. Τα δεδομένα τις εργασίας προέρχονται από την έρευνα εργατικού δυναμικού που πραγματοποιείται κάθε χρόνο στην πολιτεία Illinois των ΗΠΑ, έχοντας πάρει ως δείγμα 1000 πολίτες

και στόχος τις έρευνας είναι να εξετάσουμε τις σχέσεις μεταξύ των μεταβλητών και αν διαφέρει η ηλικία ολοκλήρωσης σπουδών ανάμεσα σε άτομα διαφορετικού φύλου και άτομα διαφορετικού ζωδίου. Τα δεδομένα που χρησιμοποιούμαι είναι τα εξής:**1. ID**: Κωδικός κάθε ερωτώμενου **2. Marital:** Οικογενειακή κατάσταση **3. Age**: Ηλικία **4. Educ**: Σε τι ηλικία ολοκλήρωσε τις σπουδές του **5. Sex:** Φύλο **6. Health**: Κατάσταση υγείας **7. Wealth**: Δείκτης που δείχνει το επίπεδο πλούτου κάθε ερωτώμενου (όπου 100 είναι ο πιο πλούσιος) **8. Zodiac**: Το ζώδιο κάθε ερωτώμενου.

Τα παραπάνω δεδομένα είναι μεταβλητές για την ανάλυση μας, οι οποίες χωρίζονται σε **ποσοτικέ**ς, δηλαδή είναι μετρήσιμες και σε **κατηγορικές η ποιοτικές** που είναι εκείνες που μεταβάλλονται κατά είδος. Η έρευνα αυτή αποτελείτε απο **3** ποσοτικές και **4** κατηφορικές η ποιοτικές καθώς και τον κωδικό **ID** του κάθε ερωτώμενου και παρουσιάζονται στην παρακάτω εικόνα:

Εικόνα 1: Κατανομή μεταβλητών

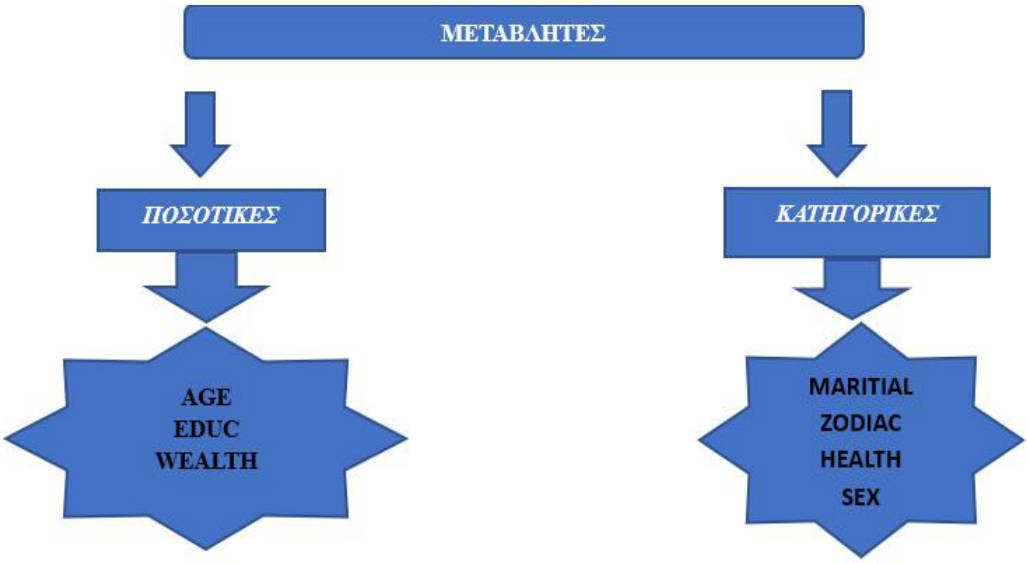

ΠΕΡΙΓΡΑΦΙΚΗ ΑΝΑΛΥΣΗ

Αρχικά ανοίγουμε το αρχείο σε μορφή .sav αφού έχουμε εισάγει τα δεδομένα από το πακέτο spss[1]. Στην συνέχεια επιβεβαιώνουμε ότι δεν υπάρχουν λάθη[2] και βλέπουμε τον τύπο[1] κάθε μεταβλητής. Στόχος της περιγραφικής ανάλυσης είναι η άμεση και ευνόητη παρουσίαση των δεδομένων. Για τις ποσοτικές μεταβλητές, γίνεται εξέταση των περιγραφικών μέτρων δηλαδή ,μέση τιμή – διάμεσος, διασπορά(τυπική απόκλιση, συντελεστής μεταβλητότητας και εύρος), των μέτρων σχετικής θέσης (τεταρτημόρια) και των μέτρων σχήματος (κύρτωση και συμμετρία).

	ΜΕΣΗ ΤΙΜΗ (mean)	ΔΙΑΜΕΣΟΣ (med)	ΤΥΠΙΚΗ ΑΠΟΚΛΙΣΗ (sd)	Q1	Q3	CV	ΑΣΥΜΜΕΤΡΙΑ	ΚΥΡΤΩΣΗ
AGE	43,85	41	16,36	31	53	0,37	0,772	2,91
EDUC	14,15	14	6,12	12	16	0,43	-0,33	3,93
WEALTH	47,95	42,3	21,4	32,4	63,5	0,44	0,44	2,02

Πίνακας 1: Παρουσίαση περιγραφικών μέτρων ποσοτικών μεταβλητών[3]

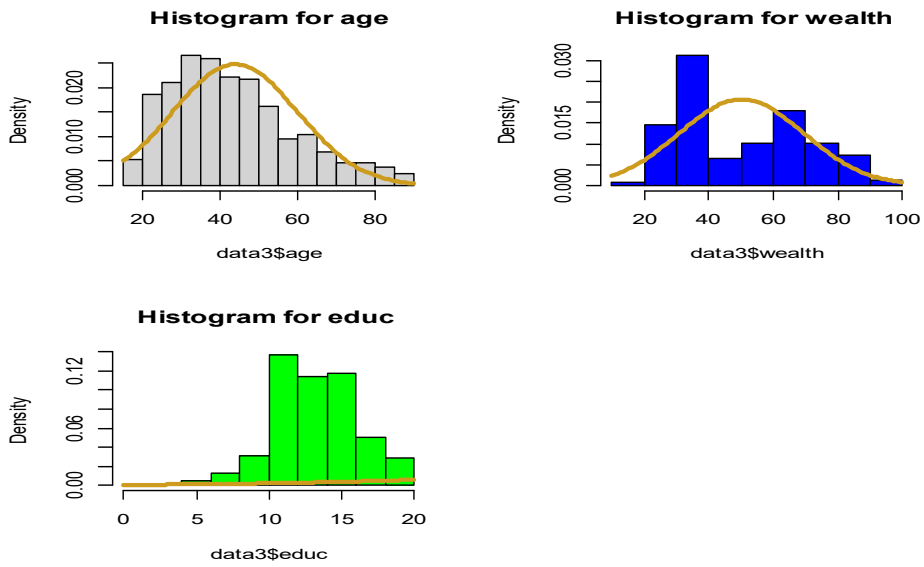

Διάγραμμα 1:Ποσοτικές μεταβλητές9

Βλέποντας, λοιπόν, τα διαγράμματα αυτά βγάζουμε το συμπέρασμα ότι καμία ποσοτική μεταβλητή δεν

[1] Παράρτημα 1ο Εντολή 1
[2] Παράρτημα 1ο Εντολή 2
[3] Παράρτημα 1ο Εντολή 4

ακολουθεί κανονική κατανομή αφού οι μπάρες των ιστογραμμάτων έχουν απόκλιση από την καμπύλη τις κανονικότητας. Παρατηρούμε ότι, το educ εκπαίδευση) έχει αρνητική ασυμμετρία ενώ wealth (δείκτης πλούτου) και age(ηλικία)έχουν θετική ασυμμετρία. Τέλος, οι μεταβλητές έχουν πλατύκυρτες κατανομές, εκτός της εκπαίδευσης που έχει λεπτόκυρτη κατανομή.

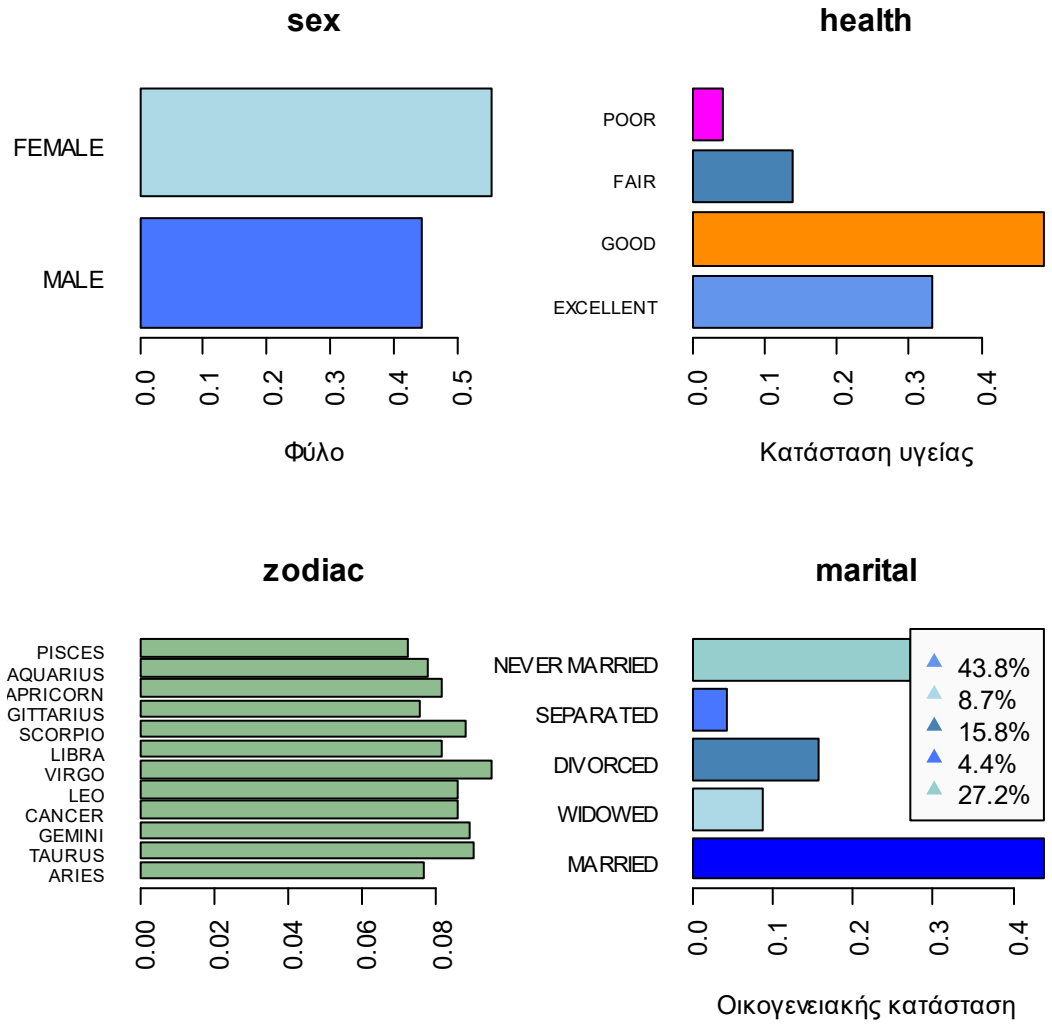

Διάγραμμα 2:ποσοτικές μεταβλητές

Συνεχίζουμε την ανάλυση με τα περιγραφικά μέτρα τον ποιοτικών μεταβλητών[4].Στα παρακάτω διαγράμματα[5] που αφορούν το φύλλο(sex)και βλέπουμε ότι οι γυναίκες είναι περισσότερες με ποσοστό 55.5% σε σχέση με τους άνδρες .Οικογενειακή κατάσταση(marital) οπού εδώ το μεγαλύτερο ποσοστό το έχουν όσοι ανήκουν στην κατηγορία "παντρεμένοι" (0,43%) ενώ το μικρότερο (0,044%) όσοι είναι "σε διάσταση".Η κατάσταση υγείας είναι καλή σε ποσοστό (0,405%) ενώ όχι καλή υγεία σε ποσοστό (0,035%).Το επικρατέστερο ζώδιο είναι ο παρθένος με (0,093%) και τα υπόλοιπα κυμαίνονται από

[4] *Παράρτημα εντολή 9*
[5] *Παράρτημα εντολή 8*

(0,07%) έως και (0,088%).

ΣΧΕΣΕΙΣ ΜΕΤΑΒΛΗΤΩΝ ΑΝΑ ΔΥΟ

Σκοπός του κεφαλαίου αυτού είναι να εξεταστούν οι σχέσεις των μεταβλητών ανά δύο, για την διεξαγωγή ορθών συμπερασμάτων. Στην παρούσα εργασία έγιναν έλεγχοι με όλους τους συνδυασμούς των μεταβλητών. Ωστόσο, αναλύονται παρακάτω οι πιο στατιστικά σημαντικοί.

Πίνακας 4 : σχέσεις και έλεγχοι ανά 2 ποσοτικών με κατηγορικές

Εξεταζόμενη σχέση	**Έλεγχος**	**Αποτελέσματα**
Educ -sex	t-test	*t = 3.712* *p-value=0,0002<0,05*
Educ -zodiac	Kruskal-Wallis	*chi-squared=7,30* *p-value=0,77>0,05*
Wealth-health	Kruskal-Wallis	*chi-squared=35,74* *p-value=<0,001*
Wealth -marital	Kruskal-Wallis	*chi-squared=32,7* *p-value<0,001*
Wealth -sex	Wilcoxon	*W=121609* *p-value=0,06>0,05*
Wealth-zodiac	Kruskal-Wallis	*chi-squared=8,34* *p-value=0,68>0,05*

Διάγραμμα 4: Ολοκλήρωση σπουδών ανάμεσα σε άτομα διαφορετικού φύλλου

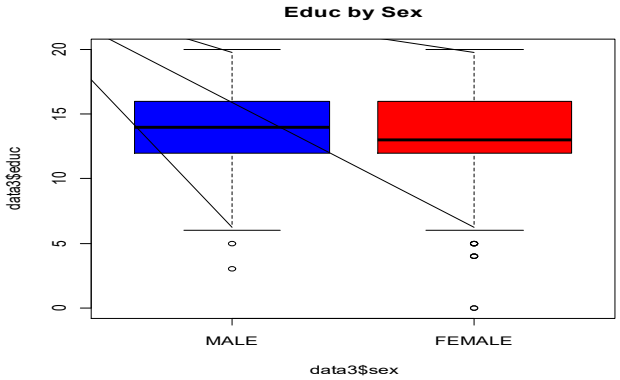

Αρχικά εξετάζεται αν υπάρχει διαφοροποίηση στα έτη ολοκλήρωσης εκπαίδευσης σε άτομα με

διαφορετικό φύλο. Αρχικά, πραγματοποιείται έλεγχος κανονικότητα της ποσοτικής μεταβλητής στους άνδρες και στις γυναίκες. Η κανονικότητα ικανοποιείται και πραγματοποιείται ανάλυση διακύμανσης και ικανοποιείται η ισότητα διακυμάνσεων (p=0,07>5%). Επομένως, πραγματοποιείται παραμετρικός έλεγχος t-test και τα αποτελέσματα δείχνουν ότι υπάρχει στατιστικά σημαντική διαφοροποίηση (p=*0,0002*) με τους άνδρες να εμφανίζουν υψηλότερη διάμεσο έτους ολοκλήρωσης σπουδών. Στην συνέχεια πραγματοποιείται ανάλυση διακύμανσης για να διαπιστωθεί αν διαφοροποιούνται τα έτη ολοκλήρωσης σπουδών σύμφωνα με το ζώδιο. Η κανονικότητα δεν ικανοποιείται για τα κατάλοιπα και για αυτό πραγματοποιείται το μη παραμετρικό τεστ Kruskal-Wallis. Τα αποτελέσματα δείχνουν ότι δεν υπάρχει στατιστικά σημαντική διαφοροποίηση στις διαμέσους (p=0,77>5%). Επιπλέον, εξετάζεται αν διαφοροποιείται ο πλούτος σύμφωνα με την κατάσταση υγείας και σύμφωνα με την οικογενειακή κατάσταση, πραγματοποιώντας ανάλυση διακύμανσης και τα αποτελέσματα έδειξαν ότι υπάρχει δεν ικανοποιείται η κανονικότητα των καταλοίπων και στις δύο περιπτώσεις και πραγματοποιείται ο μη παραμετρικός έλεγχος Kruskal-Wallis και τα αποτελέσματα έδειξαν διαφοροποίηση στη διάμεσο του πλούτου σύμφωνα με την κατάσταση υγείας και σύμφωνα με την οικογενειακή κατάσταση. Συγκεκριμένα τα άτομα με καλύτερο επίπεδο υγείας εμφανίζουν υψηλότερη διάμεσο πλούτου. Επίσης, τα άτομα που είναι παντρεμένα εμφανίζουν υψηλότερο πλούτο.

Διάγραμμα 5 : wealth by health status and wealth by marital status

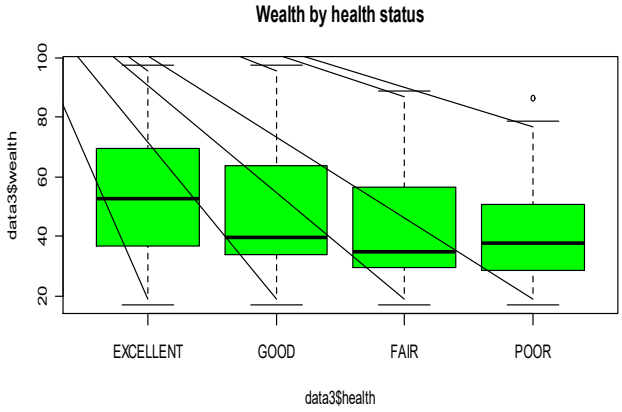

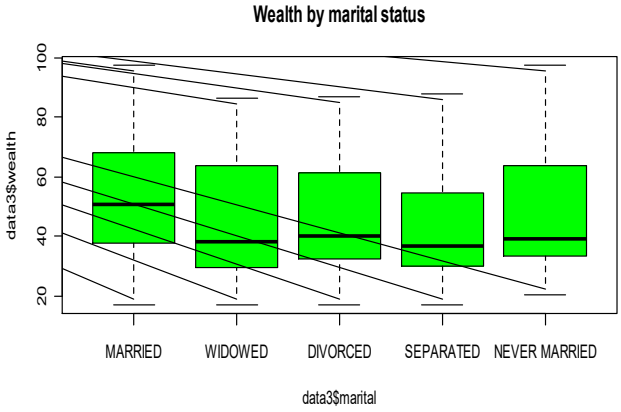

Πραγματοποιήθηκε έλεγχος t-test και δεν βρέθηκε διαφορά στον πλούτο ανάμεσα σε άτομα διαφορετικού φύλου και ανάλυση διακύμανσης και δεν παρατηρήθηκε διαφορά πλούτου σε άτομα διαφορετικού ζωδίου.

Πίνακας 5 : έλεγχοι ανά 2 ποσοτικών

Εξεταζόμενη σχέση	Έλεγχος	Αποτελέσματα
Age- wealth	*cor.test , method='spearman'*	*Rho=0,072* *P-value=0,02<0,05*
Educ - wealth	*cor.test , method='spearman'*	*Rho=0,599* *P-value<0.01*

Διάγραμμα 6: σχέσεις ποσοτικών

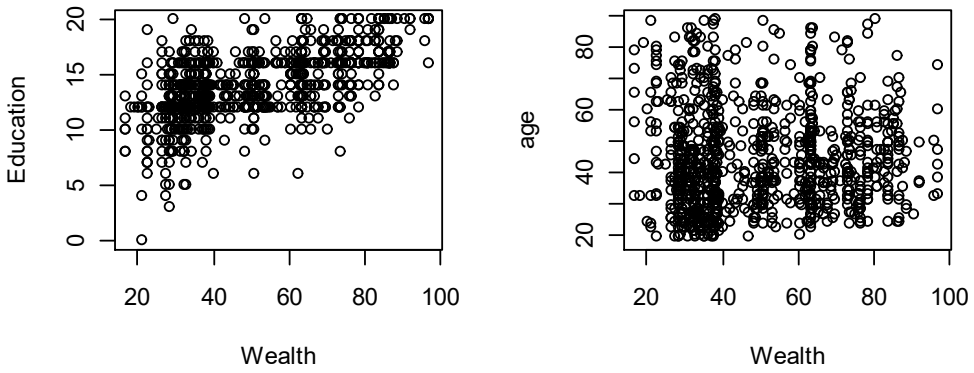

Έπειτα ελέγχουμε ποσοτικές με ποσοτικές και αφού οι ποσοτικές δεν κατανέμονται κανονικά πραγματοποιείται το μη παραμετρικό τεστ spearman. Από τον πίνακα 5 και το διάγραμμα 6 βλέπουμε ότι η το έτος ολοκλήρωσης σπουδών σε σχέση με τον δείκτη πλούτου έχουμε μια στατιστικά σημαντική σχέση δηλαδή όσο αυξάνετε το έτος που ολοκλήρωσε κάποιος τις σπουδές του ο δείκτης πλούτου είναι υψηλότερος και αφού το Rho>0 έχουν και θετική σχέση, από την άλλη η ηλικία σε σχέση με των πλούτο έχουν ασθενή στατιστική σχέση στατιστικά σημαντική θετική σχέση.

Πίνακας 6

Εξεταζόμενη σχέση	Έλεγχος	Αποτελέσματα
Health marital	**X2**	*X-squared=53,9* *p-value=0,0004<0,05*
Health sex	**X2**	*X-squared=5,7* *p-value=0,12>0,05*
Health zodiac	**X2**	*X-squared=25,91* *p-value=0,8>0,05*

Τέλος, ελέγχουμε κατηγορικές με κατηγορικές αν υπάρχει ανεξαρτησία ή συνάφεια μεταξύ των μεταβλητών: Παρατηρώντας τα αποτελέσματα του πίνακα 6 βλέπουμε ότι heath και zodiac είναι ανεξάρτητες μεταβλητές όπως και health με sex είναι ανεξάρτητες, όμως health και marital έχουν συσχέτιση και το βλέπουμε αναλυτικά στο παρακάτω διάγραμμα.

Διάγραμμα 7: barplot health - marital

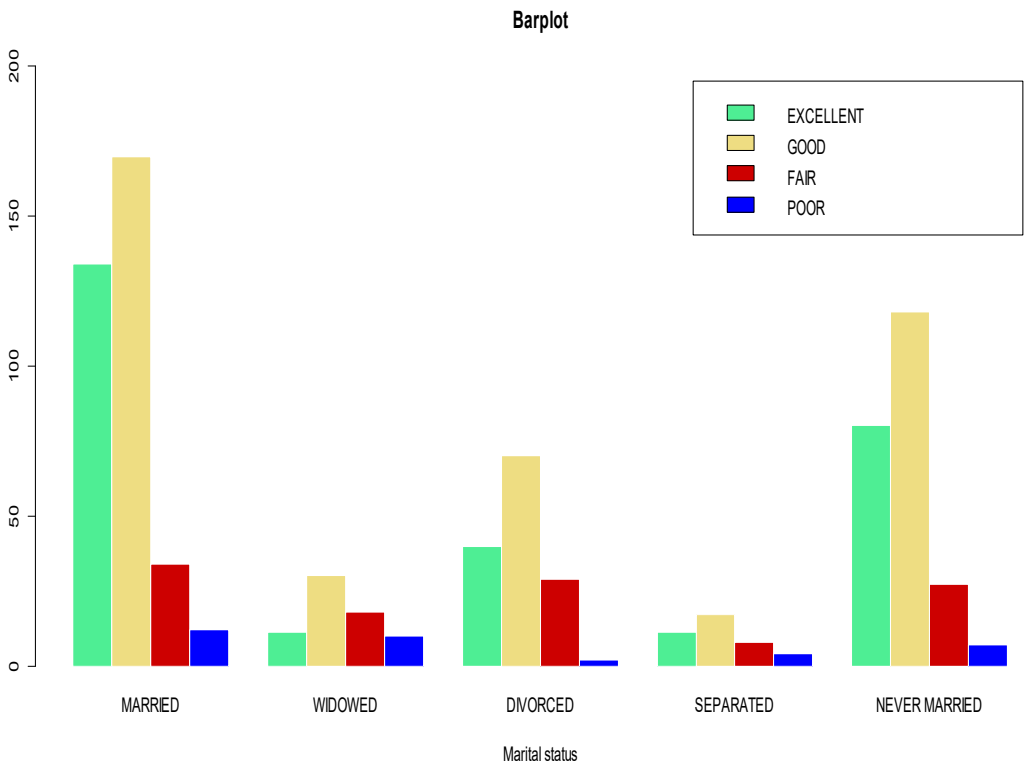

Από το διάγραμμα παρατηρούμε ότι το health είναι poor πιο συχνά στις περίπτωσης που κάποιος είναι married η widowed ενώ exellent στις περιπτώσεις που κάποιος είναι married η never married πάραυτα αξίζει να σημειώσουμε ότι η κατάσταση υγείας good εμφανίζετε σε μεγάλα ποσοστά σε όλα τα level τις μεταβλητής marital.

ΠΡΟΒΛΕΠΤΙΚΑ ΚΑΙ ΕΡΜΗΝΕΥΤΙΚΑ ΜΟΝΤΕΛΑ

Έχοντας προσδιορίσει τη σχέση των μεταβλητών ανά δύο στο προηγούμενο κεφάλαιο επιδιώκεται η ανάπτυξη του κατάλληλου προβλεπτικού και ερμηνευτικού μοντέλου για τον πλούτο του κάθε ατόμου με τις υπόλοιπες μεταβλητές. Αρχικά, διαπιστώνουμε ότι δεν αντιμετωπίζουμε πρόβλημα πολυσυγγραμικότητας αλλά δεν πληρείται η υπόθεση κανονικότητας.

Διάγραμμα 8 :Διάγραμματα καταλοίπων

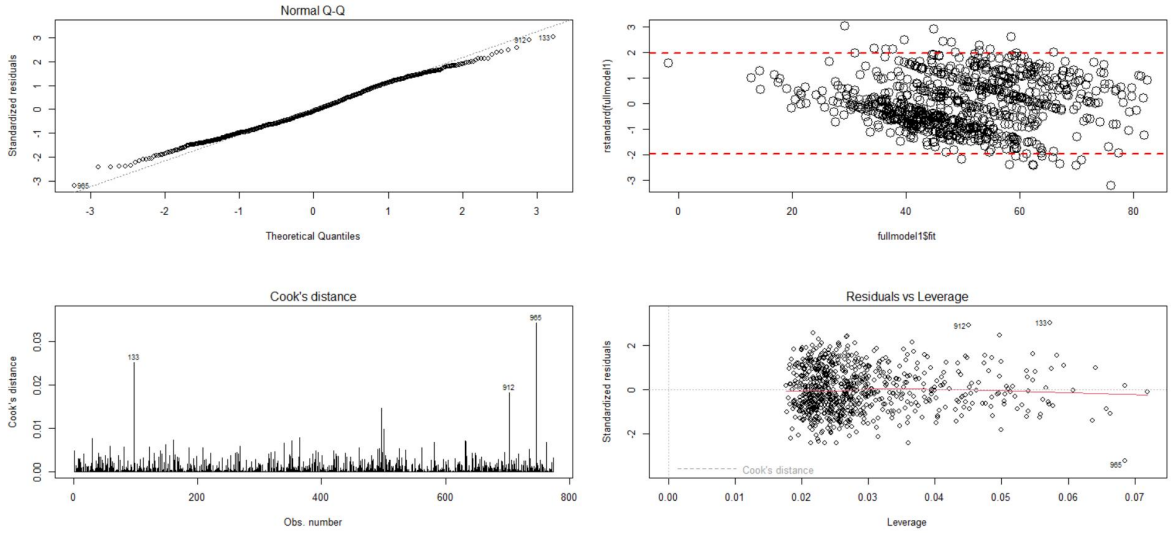

Με σκοπό την διόρθωση του προβλήματος χρησιμοποιείται ο μετασχηματισμός του λογαρίθμου της εξαρτημένης μεταβλητής και εκτελείται ένα καινούργιο μοντέλο. Από την ανάλυση παλινδρόμησης του νέου μοντέλου, διαπιστώνεται ότι δεν υπάρχει πρόβλημα πολυσυγγραμμικότητας, ότι προσεγγίζεται η συνθήκη της κανονικότητας και της ομοσκεδαστικότητας. Τέλος, μετά από κατάλληλο έλεγχο διαπιστώθηκε ότι το μοντέλο δεν επηρεάζεται από τις ακραίες τιμές .

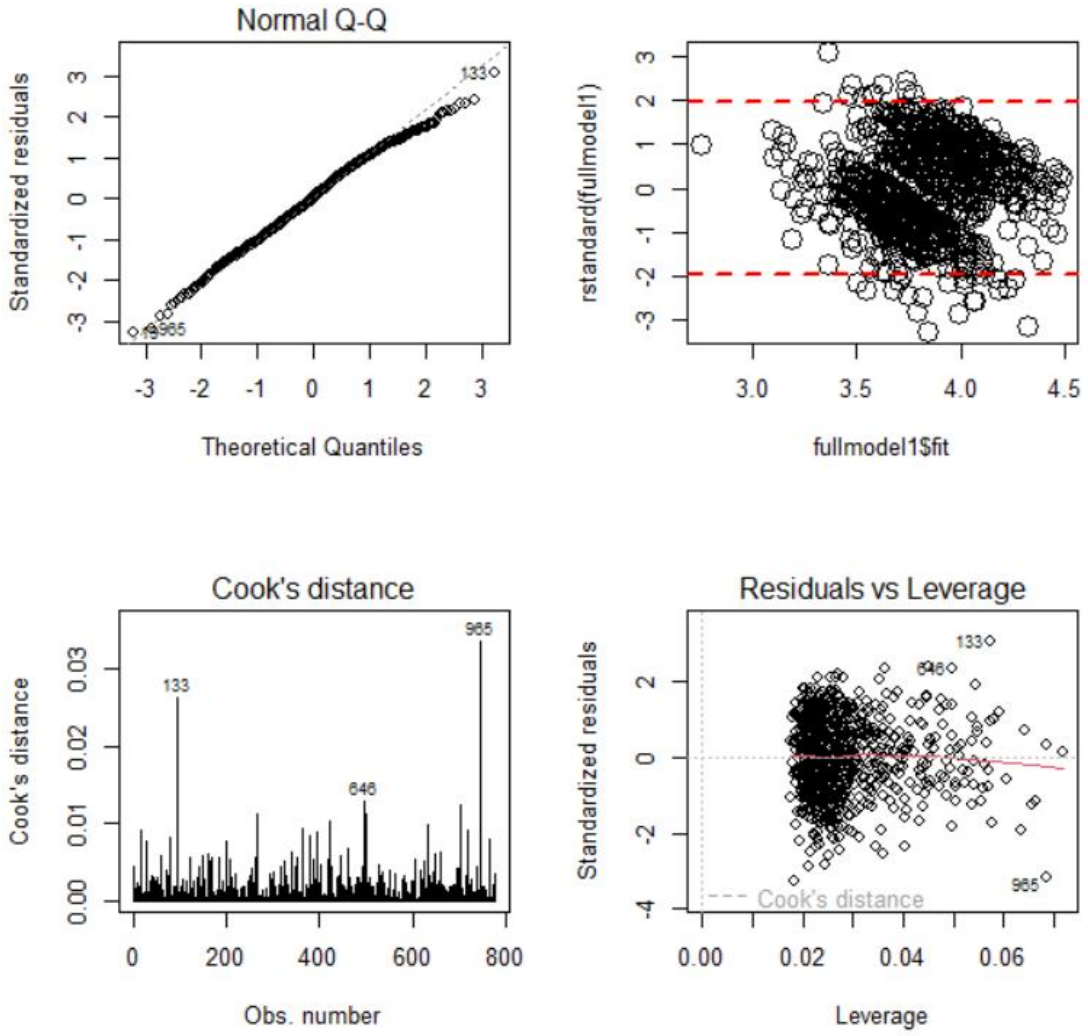

Διάγραμμα 9 :Διαγράμματα καταλοίπων του μοντέλου με το λογαριθμικό μετασχηματισμό

Το μοντέλο που προκύπτει έχει ερμηνευτική ικανότητα R^2=40,3% και στατιστικά σημαντικοί παράγοντες για τον πλούτο είναι το ζώδιο, η ηλικία, το έτος διεκπεραίωσης σπουδών, η κατάσταση υγείας και η οικογενειακή κατάσταση.

	Dependent variable		
Predictors	*Estimates*	*CI*	*p*
(Intercept)	2.64	2.47 – 2.81	**<0.001**
zodiac [TAURUS]	0.06	-0.04 – 0.17	0.254
zodiac [GEMINI]	-0.01	-0.13 – 0.10	0.797
zodiac [CANCER]	0.10	-0.01 – 0.21	0.071
zodiac [LEO]	0.09	-0.02 – 0.19	0.122
zodiac [VIRGO]	0.00	-0.10 – 0.11	0.937
zodiac [LIBRA]	0.04	-0.07 – 0.15	0.501
zodiac [SCORPIO]	0.02	-0.09 – 0.13	0.712
zodiac [SAGITTARIUS]	0.15	0.04 – 0.27	**0.007**
zodiac [CAPRICORN]	0.11	0.00 – 0.22	**0.048**
zodiac [AQUARIUS]	0.00	-0.11 – 0.12	0.985
zodiac [PISCES]	0.05	-0.06 – 0.17	0.384
health [GOOD]	-0.03	-0.08 – 0.02	0.320
health [FAIR]	-0.09	-0.16 – -0.02	**0.018**
health [POOR]	0.03	-0.09 – 0.15	0.633
marital [WIDOWED]	-0.08	-0.18 – 0.01	0.088
marital [DIVORCED]	-0.09	-0.16 – -0.03	**0.005**
marital [SEPARATED]	-0.16	-0.27 – -0.05	**0.004**
marital [NEVER MARRIED]	-0.09	-0.15 – -0.03	**0.003**
sex [FEMALE]	0.00	-0.05 – 0.05	0.995
educ	0.08	0.07 – 0.09	**<0.001**
age	0.00	0.00 – 0.00	**0.003**
Observations	774		
R^2 / R^2 adjusted	0.403 / 0.386		

Αν κάποιος ανήκει στο ζώδιο του κριού και είναι άνδρας, παντρεμένος με πολύ κατάσταση υγείας με μηδενική ηλικία και έτος σπουδών ο πλούτος είναι exp(2,64). Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα ανήκει στο ζώδιο του τοξότη και το άλλο στου κριού με τα άλλα χαρακτηριστικά να είναι ίδια όπου ο Τοξότης λαμβάνει (exp(0,15)-1)*100% παραπάνω πλούτο. Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα ανήκει στο ζώδιο του αιγόκερου και το άλλο στου κριού με τα άλλα χαρακτηριστικά να είναι ίδια όπου ο Αιγόκερος λαμβάνει (exp(0,11)-1)*100% παραπάνω πλούτο. Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα έχει φτωχή υγεία και το άλλο πολύ καλή υγεία με τα

άλλα χαρακτηριστικά να είναι ίδια όπου το άτομο με τη φτωχή υγεία έχει μικρότερο πλούτο (exp(-0,09)-1)*100%. Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα είναι διαζευγμένο και το άλλο παντρεμένο με τα άλλα χαρακτηριστικά να είναι ίδια όπου το άτομο που είναι διαζευγμένο να έχει μικρότερο πλούτο (exp(-0,09)-1)*100%. Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα έχει τελειώσει τις σπουδές του κατά ένα έτος περισσότερο με τα άλλα χαρακτηριστικά να είναι ίδια να έχει μεγαλύτερο πλούτο (exp(0,08)-1)*100%. Στατιστικά σημαντική διαφορά παρατηρείται ανάμεσα σε δύο άτομα όπου το ένα είναι μεγαλύτερο κατά ένα έτος περισσότερο με τα άλλα χαρακτηριστικά να είναι ίδια να έχει μεγαλύτερο πλούτο (exp(0,0025)-1)*100%.

Συμπεράσματα

Στα πλαίσια της διεξαγωγής της ανάλυσης διαπιστώθηκε ότι ο πλούτος επηρεάζεται από το ζώδιο, η ηλικία, το έτος διεκπεραίωσης σπουδών, η κατάσταση υγείας και η οικογενειακή κατάσταση.

Αναφορές

ΦΟΥΣΚΑΚΗΣ, Α. (2013). Ανάλυση δεδομένων με χρήση της R, Εκδόσεις ΤΣΟΤΡΑΣ, Αθήνα

ΚΟΥΤΡΑΣ et al (2016). Ανάλυση παλινδρόμησης- θεωρία και εφαρμογές, Εκδόσεις ΣΤΑΜΟΥΛΗ, Αθήνα

ΠΑΡΑΡΤΗΜΑ 1ο:εντολές και περιγραφικά μέτρα

Εντολή 1 : Εισαγωγή δεδομένων και έλεγχος τύπου μεταβλητών:

```
install.packages("foreign")
library(foreign)
data3<-read.spss(choose.files(),to.data3.frame = TRUE,add.undeclared.levels = "no")
str(data3)
```

Εντολή 2:έλενχος για τυχών λάθη στις κατηγορικές μεταβλητές

```
table(data3$marital)
table(data3$sex)
table(data3$health)
table(data3$zodiac)
```

Εντολη 3:έλενχος για τυχών λάθη στις ποσοτικές μεταβλητές:

```
summary(data3$wealth)
summary(data3$age)
summary(data3$educ)

sd(na.omit(data3$wealth))
sd(na.omit(data3$age))
```

sd(na.omit(data3$wealth))

εντολή 8:διαγραμμα φυλλου

par(mfrow=c(2,2))

barplot(prop.table(table(data3$sex)), xlab='Φύλο',main="Ραβδόγραμμα του

φύλου",cex.names=0.9,col=c("royalblue1","lightblue"),horiz=T,las=2)

legend("bottomright",col=c("royalblue1","steelblue"),pch=17,legend=paste(round(prop.table(ta
ble(d

ata$sex))*100,digits=1),"%",sep=""),bg="grey98 ")

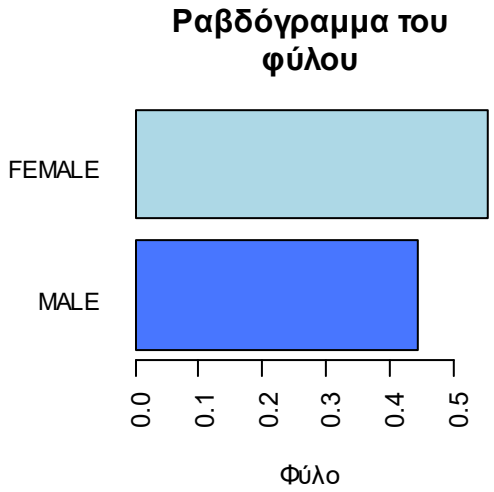

εντολη 9 :παρουσιαση περιγραφηκων μετρον

```
data3$marital[data3$marital=="NA"]=NA

table(data3$marital)

table(data3$sex)

table(data3$health)

table(data3$zodiac)

prop.table(table(data3$marital))

prop.table(table(data3$sex))

prop.table(table(data3$health))

prop.table(table(data3$zodiac))
```

Εντολη 5 :διαγραματα barplot

```
par(mfrow=c(2,2))

barplot(prop.table(table(data3$sex)),
xlab='Φύλο',main="sex",cex.names=0.9,col=c("royalblue1","lightblue"),horiz=T,las=2)

legend("bottomright",col=c("cornflowerblue","darkseagreen"),pch=17,legend=paste(round(pro
p.table(table(d

ata$sex))*100,digits=1),"%",sep=""),bg="grey98 ")


barplot(prop.table(table(data3$health)),xlab='Κατάσταση
υγείας',main="health",cex.names=0.7,col=c("cornflowerblue","darkorange","steelblue","mage
nta" ),horiz=T,las=2)

legend("topright",col=c( "cornflowerblue","lightblue","magenta","royalblue1","paleturquoise
3"

),pch=17,legend=paste(round(prop.table(table(data3$health))*100,digits=1),"%",sep=""),bg="g
rey98

")

mycol="darkseagreen"

barplot(prop.table(table(data3$zodiac)),main="zodiac",col=mycol,cex.names=0.7,las=2,horiz=T)
```

```
barplot(prop.table(table(data3$marital)), cex.names = 0.8, col = c("blue", "lightblue", "steelblue", "royalblue1", "paleturquoise3"), xlab = 'Οικογενειακής κατάσταση', main = "marital", horiz = TRUE, las = 2)

legend("topright", col = c("cornflowerblue", "lightblue", "steelblue", "royalblue1", "paleturquoise3"), pch = 17, legend = paste(round(prop.table(table(data3$marital)) * 100, digits = 1), "%", sep = ""), bg = "grey98")
```

Εντολη 6:διαγραμμα ιστογραμματον

```
par(mfrow=c(2,2))


hist(data3$age,main='Histogram for age',probability=T,col='lightgrey')

x=na.omit(data3$age)

m=mean(x)

s=sd(x)

curve(dnorm(x,m,s),add=T,col='goldenrod3',lwd=3)


hist(data3$wealth,main='Histogram for wealth ',probability=T,col='blue')

x=na.omit(data3$wealth)

m=mean(x)

s=sd(x)

curve(dnorm(x,m,s),add=T,col='goldenrod3',lwd=3)


hist(data3$educ,main='Histogram for educ ',probability=T,col='green')

x=na.omit(data3$educ

m=mean(x)

s=sd(x)

curve(dnorm(x,m,s),add=T,col='goldenrod3',lwd=3)
```

Εντολή 4:: Υπολογισμός περιγραφικών μέτρων για τις ποσοτικές μεταβλητές

```
install.packages("psych")
library(psych)
describe(data3[,c(3,4,7)])
summary(data3[,c(3,4,7)])
```

Εντολή 7 : Κάνω έλεγχο κανονικότητας των ποσοτικών μεταβλητών

```
install.packages("nortest")
library("nortest")
for (i in c(3,4,7)){
print(lillie.test(data3[,i]))}
```

ΠΑΡΑΡΤΗΜΑ 2ο: ελέγχους μεταβλητών

εντολη 11:ελεγχος educ με την διτιμη sex

```
#katig me 2 levels kai posotik

#educ+sex

by(data3$educ,data3$sex,shapiro.test)

#no normality-p<5%

median(na.omit(data3$educ[data3$sex=="MALE"]))

mean(na.omit(data3$educ[data3$sex=="MALE"]))

median(na.omit(data3$educ[data3$sex=="FEMALE"]))

mean(na.omit(data3$educ[data3$sex=="FEMALE"]))

#AFOU MEDIAN KONTA STO MEAN KAI DEIGMA MEGALO THEWRW OTI PROSEGGIZETAI H

#KANONIKOTHTA

var.test(data3$educ~data3$sex)

t.test(data3$educ~data3$sex,var.equal=T)

#p-valye<5%

boxplot(data3$educ~data3$sex,main="Educ by Sex",col=c("blue","red"))
```

εντολη 12 :ελεγχος wealth με την διτιμη sex

```
#wealth+sex

by(data3$wealth,data3$sex,shapiro.test)

#no normality-p<5%

median(na.omit(data3$wealth[data3$sex=="MALE"]))

mean(na.omit(data3$wealth[data3$sex=="MALE"]))

median(na.omit(data3$wealth[data3$sex=="FEMALE"]))

mean(na.omit(data3$wealth[data3$sex=="FEMALE"]))

#AFOU MEDIAN oxi KONTA STO MEAN

wilcox.test(data3$wealth~data3$sex,var.equal=T)
```

```
#p-valye<5% oxi se 10% nai
boxplot(data3$wealth~data3$sex,main="Wealth by Sex",col=c("blue","red"))
```

Εντολη 13:ελεγχος educ με zodiac

```
#educ+zodiac
anova1=aov(data3$age~data3$zodiac)
shapiro.test(anova1$res)
median(anova1$res)
mean(anova1$res)
kruskal.test(data3$age~data3$zodiac)
#den iparxei simantiki diafora
```

Εντολη 14:ελεγχος wealth με zodiac

```
#wealth+zodiac
anova2=aov(data3$wealth~data3$zodiac)
shapiro.test(anova2$res)
median(anova2$res)
mean(anova2$res)
kruskal.test(data3$wealth~data3$zodiac)
#den iparxei simantiki diafora
```

Εντολη 15:ελεγχος wealth με health

```
#wealth+health
anova3=aov(data3$wealth~data3$health)
shapiro.test(anova3$res)
median(anova3$res)
mean(anova3$res)
kruskal.test(data3$wealth~data3$health)
# iparxei simantiki diafora
boxplot(data3$wealth~data3$health,main="Wealth by health status",col="green")
```

Εντολη 16 :ελεγχος wealth με marital

```
#wealth+marital
anova4=aov(data3$wealth~data3$marital)
shapiro.test(anova4$res)
median(anova4$res)
mean(anova4$res)
kruskal.test(data3$wealth~data3$marital)
# iparxei simantiki diafora
boxplot(data3$wealth~data3$marital,main="Wealth by marital status",col="green")
```

Εντολη 17:ελεγχος wealth με educ

```
#sxesh posotikwn
#wealth+educ
shapiro.test(data3$wealth)
shapiro.test(data3$educ)
cor.test(data3$wealth,data3$educ,method="spearman")
plot(data3$wealth,data3$educ,xlab="Wealth",ylab="Education")
```

Εντολή 18:ελεγχος wealth με age

```
#wealth+age
shapiro.test(data3$wealth)
shapiro.test(data3$age)
cor.test(data3$wealth,data3$age,method="spearman")
plot(data3$wealth,data3$age,xlab="Wealth",ylab="Education")
```

Εντολή 19:ελεγχος health με zodiac:

```
tab15<-table(data3$health,data3$zodiac)

chi15<-chisq.test(tab15)

chi15$expected

chi15<-chisq.test(tab15,simulate.p.value=TRUE)
```

Εντολή 20:ελεγχος health με sex

```
tab12<-table(data3$health,data3$sex)

chi12<-chisq.test(tab12)
```

Εντολή 21:ελεγχος health με sex

```
tab15<-table(data3$health,data3$marital)

chi15<-chisq.test(tab15)

chi15$expected

chi15<-chisq.test(tab15,simulate.p.value=TRUE)

barplot(tab15,xlab="Marital
status",main="Barplot",beside=T,col=c("seagreen2","lightgoldenrod","red3","blue"),border="
white",ylim=c(0,200),legend=levels(data3$health))
```

ΠΑΡΑΡΤΗΜΑ 3ο:μοντελο και μετασχυματισμος

```
fullmodel1 <- lm(data3$wealth~zodiac+health+marital+sex+educ+age , data= data3)
summary(fullmodel1)
install.packages("car")
library(car)
#polisigrammikotita
vif(fullmodel1)
#normality
plot(fullmodel1,which=2)
shapiro.test(fullmodel1$res)
#homoskedasticity-linearity
plot( fullmodel1$fit, rstandard(fullmodel1), cex=2)
abline( h= 1.96, col='red', lwd=2, lty=2 )
abline( h=-1.96, col='red', lwd=2, lty=2 )
quantcut<-function(x){cut(x,breaks=quantile(x),include.lowest=T)}
qfits<-quantcut(fullmodel1$fit)
leveneTest(rstandard(fullmodel1),qfits)#p>5%-omoskedastikotita
#
residualPlots(fullmodel1)
```

```
fullmodel1 <- lm(log(data3$wealth)~zodiac+health+marital+sex+educ+age , data= data3)
summary(fullmodel1)
install.packages("car")
library(car)
#polisigrammikotita
vif(fullmodel1)
#normality
plot(fullmodel1,which=2)
shapiro.test(fullmodel1$res)
#homoskedasticity-linearity
plot( fullmodel1$fit, rstandard(fullmodel1), cex=2)
```

```
abline( h= 1.96, col='red', lwd=2, lty=2 )
abline( h=-1.96, col='red', lwd=2, lty=2 )
quantcut<-function(x){cut(x,breaks=quantile(x),include.lowest=T)}
qfits<-quantcut(fullmodel1$fit)
leveneTest(rstandard(fullmodel1),qfits)
#p>5%-omoskedastikotita
#
residualPlots(fullmodel1)
#outlier
plot(fullmodel1,which=4)
abline(h=4/(nrow(data)-2-1),col='blue',lty=2)
plot(fullmodel1,which=5)

tab_model(fullmodel1)



install.packages("sjPlot")
library(sjPlot)
library(sjmisc)
tab_model(fullmodel1)
```